


SVM & KERNEL SVM

課程大綱：



- SVM理論介紹（線性可分與非線性可分）
 - SVM函數介紹

SVM理論介紹：如何對資料做分類？【線性可分】

Hyperplanes



- 支援向量機(SVM) : 是一種分類的演算法，多用於資料分類預測，使用超平面與向量的概念，達到分類效果，多用於非線性、高維度資料，如臉部辨識。
- 超平面 (hyperplane) : 在2群資料中找出最佳距離，此距離為距2群資料邊際之最大處，錯誤率最低，具有此距離的性質之平面為超平面。
- 支援向量 (Support Vectors) : 落於超平面上，並且用於區分資料的重要向量。
- 運算方式 : 經訓練資料數據經計算可得到向量，並由條件式分出資料群組。




- 分類過程如下：

1. 訓練樣本求出支援向量 -> 2. 資料點 x 帶入函數 $f(x) = w*x - b$ -> 3. 由 $f(x) \geq 1$ or $f(x) \leq -1$ 算出數值分類。

- 分類說明：<http://www.doc88.com/p-273339024512.html>

SVM-KERNEL函數：如何對資料做分類？【非線性可分】



- SVM-Kernel：是一種**映射函數**，使用維度轉換原理，將低維度不可分轉為高維度可分，對**非線性**資料分類，又稱核函數。
- Kernel trick：將映射函數簡化的一種**技巧**，當映射到高維度時，計算變複雜，此時**轉換內積**方式，就可以簡化計算，意思是在低維度運算等價於高維度的結果，就是**不在**高維度映射後再內積計算。

$$\begin{aligned}
 K(x, z) &= (x^T z)^2 = \left(\sum_{i=1}^n x_i z_i \right) \left(\sum_{j=1}^n x_j z_j \right) = \sum_{i=1}^n \sum_{j=1}^n x_i x_j z_i z_j \\
 &= \sum_{i=1}^n \sum_{j=1}^n (x_i x_j)(z_i z_j) = \phi(x)^T \phi(z)
 \end{aligned}$$

<http://blog.csdn.net/>

$$\phi(x) = \begin{bmatrix} x_1 x_1 \\ x_1 x_2 \\ x_1 x_3 \\ x_2 x_1 \\ x_2 x_2 \\ x_2 x_3 \\ x_3 x_1 \\ x_3 x_2 \\ x_3 x_3 \end{bmatrix}$$

$$\phi(z) = \begin{bmatrix} z_1 z_1 \\ z_1 z_2 \\ z_1 z_3 \\ z_2 z_1 \\ z_2 z_2 \\ z_2 z_3 \\ z_3 z_1 \\ z_3 z_2 \\ z_3 z_3 \end{bmatrix}$$

- 計算方式：使用kernel做內積轉換，不在高維度做計算，但結果是等價。

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle \phi(x_i), \phi(x_j) \rangle \\ \text{s.t.}, \quad & \alpha_i \geq 0, i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j) \\ \text{s.t.}, \quad & \alpha_i \geq 0, i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

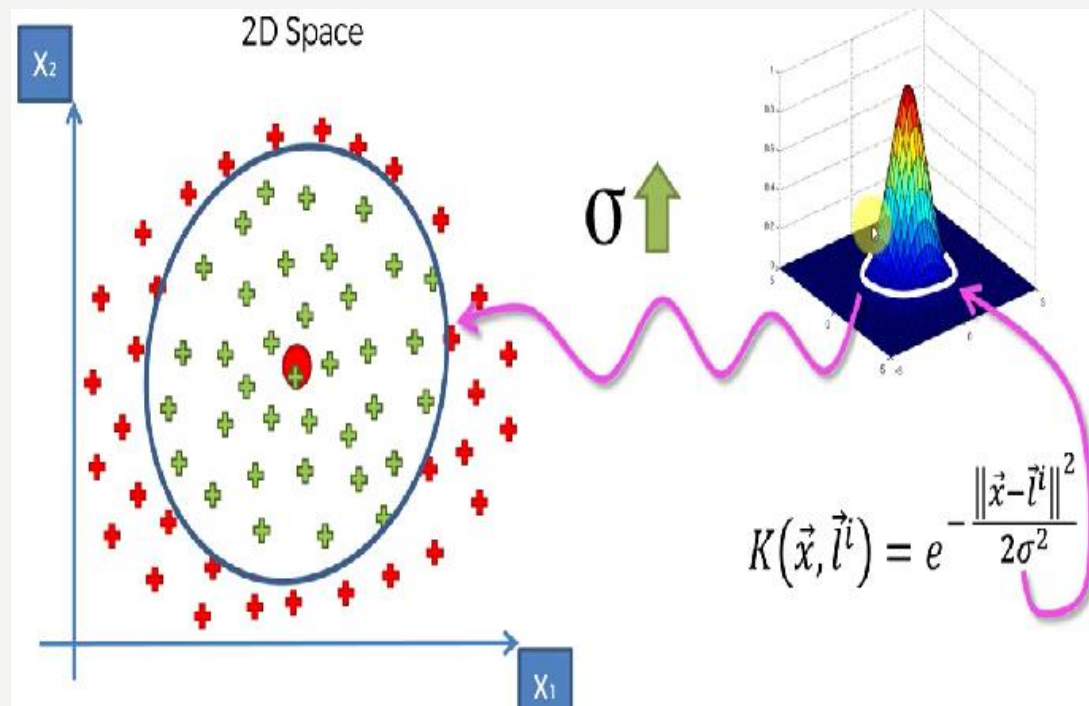
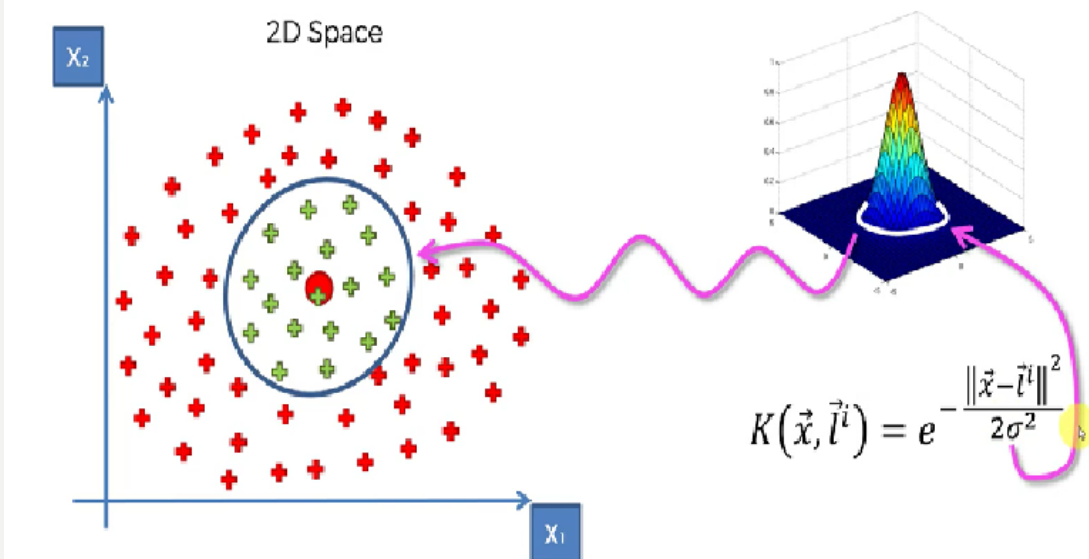
- 參考網址：

<https://zh.wikipedia.org/wiki/%E6%94%AF%E6%8C%81%E5%90%91%E9%87%8F%E6%9C%BA>


常見核函數：

- **高斯函數 (RBF)**：全名為：(Radial Basis function)，又稱徑向基函數，是一種以**中心點**分類的核函數，分類概念如下：中心點為*i*，資料點為*x*，函數結構如下：
 $k(x,i) = \exp(-1/2\sigma^2) * ||x-i||^2$ ，其中 **σ** 是分類邊界的範圍，**若*x*很接近中心點**，則 **$k(x,i)$ 接近1**，**若*x*遠離中心點**， **$k(x,i)$ 接近0**，達到分類，可做無限維度的延伸，分布類似高斯分布，故稱高斯函數。


The Gaussian RBF Kernel




不同的 σ 值的結果比較： $\text{gamma} = 1/2\sigma^2$



$$\exp(-1\|\mathbf{x} - \mathbf{x}'\|^2)$$



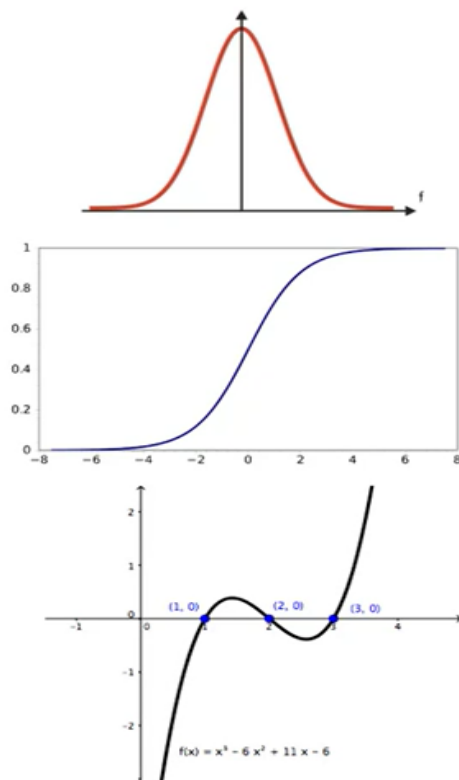
$$\exp(-10\|\mathbf{x} - \mathbf{x}'\|^2)$$



$$\exp(-100\|\mathbf{x} - \mathbf{x}'\|^2)$$

其他核函數：

Types of Kernel Functions



Gaussian RBF Kernel

$$K(\vec{x}, \vec{l}^i) = e^{-\frac{\|\vec{x} - \vec{l}^i\|^2}{2\sigma^2}}$$

Sigmoid Kernel

$$K(X, Y) = \tanh(\gamma \cdot X^T Y + r)$$

Polynomial Kernel

$$K(X, Y) = (\gamma \cdot X^T Y + r)^d, \gamma > 0$$

- 函數介紹網址：<http://mlkernels.readthedocs.io/en/latest/kernels.html>